

AI赋能量子计算任务调度系统

技术白皮书

Quantum-RL Co-optimized Intelligent Scheduling System

项目信息	
版本	v1.0
日期	2026年7月27日
团队	量子RL调度团队
代码仓库	github.com/xiabai2008/quantum-rl-scheduler
开源协议	MIT License

本技术白皮书所有数字均来自可复现的实验结果
审计脚本 `scripts/ci/audit_authoritative_metrics.py` 验证通过

摘要

量子计算正从实验室走向产业化，但异构量子-经典混合计算环境下的任务调度仍是关键瓶颈。现有量子云平台普遍采用先来先服务（FCFS）等简单启发式规则，无法有效应对动态任务到达、异构算力分配和服务等级目标（SLO）约束。本文提出一种基于近端策略优化（PPO）的强化学习调度系统，通过14维观测空间感知量子比特状态、队列特征、物理噪声和拓扑信息，在量子、经典和混合三种执行模式间做出智能分配决策。在50 seeds × 5 episodes (N=250) 的严格统计评估中，PPO相比FCFS基线实现了+88.3%的综合调度性能提升（Mann-Whitney U检验， $p=1.032 \times 10^{-42}$ ，rank-biserial效应量=-0.71）。系统已完成与天衍量子计算云平台的SDK全链路对接，284次真机调用成功率100%。本文同时诚实报告了方法的局限性：等待时间与吞吐量之间存在帕累托权衡，量子赋能AI方向（量子退火加速DQN）的性能提升未达统计显著水平。

关键词：量子计算调度；强化学习；PPO；异构计算；多目标优化；云平台

1. 背景与问题定义

1.1 量子计算产业化趋势

量子计算作为下一代计算范式，在量子化学模拟、组合优化、密码学等领域展现出超越经典计算的潜力。近年来，以IBM Quantum、AWS Braket、中国电信天行云为代表的量子云平台相继投入运营，量子计算资源正以云服务的形式向科研和产业用户开放。据行业报告，全球量子计算市场规模预计从2024年的约90亿美元增长至2030年的数百亿美元量级。

1.2 任务调度痛点

当前量子云平台的调度系统面临三大核心挑战：

1. 异构算力协同：任务可能适合量子执行、经典执行或量子-经典混合执行，不同任务类型对资源的需求差异巨大。简单的路由规则无法充分利用异构资源。
2. 动态任务到达：任务以泊松过程动态到达，队列长度和等待时间持续变化，调度器需要实时感知系统状态并做出自适应决策。
3. 多目标约束：调度需要同时优化量子比特利用率、任务吞吐量、等待时间和SLO违约率等多个相互冲突的目标。

1.3 现有方法局限

当前主流调度策略包括：

- FCFS（先来先服务）：不考虑任务特征和资源状态，在负载波动时效率低下
- SJF（短作业优先）：需要预知任务执行时间，且可能导致长任务饥饿
- Greedy（贪心）：容易陷入局部最优，在我们的实验中表现甚至差于FCFS
- 基于规则的调度：依赖人工设计规则，难以覆盖复杂场景

1.4 为什么强化学习适合


强化学习（RL）天然适合序贯决策问题：

- 能够从与环境的交互中自动学习最优策略，无需人工设计调度规则
- 可以处理高维状态空间和复杂的奖励函数设计
- 通过多随机种子训练和评估，可以获得统计显著的性能提升
- 策略网络推理延迟极低（P50约0.5-3ms），满足实时调度需求

2. 系统设计

2.1 整体架构

系统采用三层解耦架构设计：



2.2 三级降级策略

为确保系统可靠性，调度引擎实现了三级降级机制：

1. 第一级：PPO模型推理（正常状态）
2. 第二级：规则引擎兜底（模型加载失败或推理异常时）
3. 第三级：默认动作分配 + 系统告警（规则引擎也不可用时）

2.3 环境设计

2.3.1 状态空间（14维）

观测向量为归一化到[0,1]的14维连续向量：

维度	含义	类别
0	量子比特可用率	资源状态
1	队列长度（归一化）	队列状态
2	平均等待时间（归一化）	性能指标
3	量子比特平均保真度	资源状态
4	经典计算资源负载	资源状态
5	量子专用队列占比	队列状态
6	时段（昼夜模拟）	环境
7	当前任务紧急程度	任务特征
8	当前任务是quantum类型	任务特征
9	当前任务是classical类型	任务特征
10	单比特门保真度	物理噪声
11	两比特门保真度	物理噪声
12	耦合图密度	拓扑特征
13	量子比特平均连通度	拓扑特征

2.3.2 动作空间（3维）

离散动作空间包含三种执行模式：

- 动作0（CLASSICAL）：分配到经典计算资源执行
- 动作1（QUANTUM）：分配到量子计算资源执行
- 动作2（HYBRID）：量子-经典混合协同执行

2.3.3 奖励函数

采用多目标奖励函数，平衡资源利用效率和用户体验：

即时奖励：

- 经典执行成功：+8.0
- 量子执行成功： $+10.0 \times \text{加速比} \times \text{保真度因子} + 3.0$ （成功奖励）
- 混合执行成功： $+7.0 \times \text{混合因子} + 3.0$ （成功奖励）

惩罚项：

- 资源错配（如将纯经典任务分配到量子资源）：-2.0
- 任务等待超过阈值后每步惩罚： $-0.1 \times \text{超时比例}$
- 量子比特利用率低于30%时：-1.0

2.4 天衍云平台对接

系统通过cqlib SDK与中国电信天衍量子计算云平台对接：

- 支持三台量子计算机：天衍-S（287比特）、天衍-SW（72比特）、天衍-TN（176比特）
- 实现三态熔断器：闭合→打开→半开，连续3次失败自动降级
- 支持量子电路构造、提交、轮询执行、结果解析全链路
- Prometheus集成7项核心监控指标

3. 核心算法

3.1 PPO算法选型

选择Proximal Policy Optimization（PPO）作为核心算法，理由如下：

对比维度	PPO	DQN	A2C
离散/连续动作	两者皆可	仅离散	两者皆可
训练稳定性	高（裁剪目标函数）	中（经验回放）	低（同步更新）
样本效率	中	高	低
超参数鲁棒性	高	中	低
实现复杂度	低-中	中	低

PPO通过裁剪的代理目标函数（clip range=0.2）限制每次策略更新的幅度，在训练稳定性和样本效率之间取得了良好平衡，是深度强化学习在工程实践中的首选算法。

3.2 网络架构

采用MLP（多层感知机）策略网络：

- 输入层：14维状态向量
- 隐藏层1：64神经元，Tanh激活
- 隐藏层2：64神经元，Tanh激活
- 策略输出层：3维，Softmax激活（动作概率）
- 价值输出层：1维，线性激活（状态价值估计）

总参数量约19K，模型文件仅77KB，CPU推理延迟P50约3ms，ONNX优化后可达0.5ms。

3.3 PPO超参数

超参数	值
学习率	3×10^{-4}
每次更新步数	2048
批次大小	64
更新轮数	10
折扣因子 γ	0.99
GAE λ	0.95
裁剪范围	0.2
熵正则系数	0.01
价值函数系数	0.5
梯度裁剪	0.5
训练总步数	50,000步

3.4 8种对比策略

实验中对比了8种调度策略：

1. PPO（本文方法）：14维观测空间PPO智能体
2. DQN：Deep Q-Network基线
3. SJF：短作业优先
4. FCFS：先来先服务（工业界默认基线）
5. Random：随机策略
6. Greedy：贪心策略（总是选择即时奖励最高的动作）

7. Quantum-Only: 总是分配到量子资源
8. Classical-Only: 总是分配到经典资源

4. 实验结果

4.1 实验设置

参数	值
随机种子数	50
每种子Episode数	5
总独立运行次数	250
每Episode最大任务数	200
队列最大长度	30
初始队列大小	[5, 20]随机
统计检验方法	Mann-Whitney U检验
显著性水平 α	0.05 (Bonferroni校正后0.0018)
Bootstrap重抽样	10,000次

4.2 主结果：8策略性能对比

排名	策略	平均奖励	标准差	相对FCFS提升	p值
1	PPO	2746.94	1160.72	+88.3%	1.03×10^{-42}
2	DQN	1527.65	124.02	+4.7%	2.15×10^{-12}
3	SJF	1462.39	134.32	+0.2%	0.052 (不显著)
4	FCFS	1458.77	60.47	基线	—
5	Random	1247.17	385.76	-14.5%	—
6	Greedy	-25.95	625.52	-101.8%	—
7	Quantum-Only	-920.54	232.68	-163.1%	—

排名	策略	平均奖励	标准差	相对FCFS提升	p值
8	Classical-Only	-1128.29	59.46	-177.3%	—

- 核心发现：
- PPO以2746.94的平均奖励大幅领先所有基线，相比FCFS提升88.3%
 - 统计显著性极强： $p=1.03\times10^{-42}$ ，效应量rank-biserial=-0.71（大效应量）
 - DQN虽然也显著优于FCFS（+4.7%），但提升幅度远小于PPO
 - SJF与FCFS无显著差异（ $p=0.052>0.0018$ ）
 - 极端策略（Quantum-Only/Classical-Only）表现最差，证明智能资源分配的必要性

4.3 资源利用率分析

PPO策略通过动态分配任务到合适的资源类型，有效提升了量子比特利用率：

- FCFS基线量子比特利用率约33.6%
- PPO策略在消融实验中实现了约30%的利用率提升
- 智能体学会了在量子资源空闲时优先分配量子任务、在队列积压时合理分流到经典资源

4.4 吞吐量-等待时间权衡

需要诚实指出：PPO在提升吞吐量的同时，平均等待时间有所增加（约+51%）。这不是bug，而是多目标优化的帕累托权衡：

- PPO选择接受稍长的等待时间，换取更高的整体吞吐量和资源利用率
- 通过调整奖励函数中利用率权重和等待时间惩罚的权重，可以在帕累托前沿上灵活移动
- 不同业务场景（批处理vs交互式）可以选择不同的权重配置

4.5 多场景压力测试与场景-算法适配决策树

我们在4种典型负载场景（加上量子资源波动补充场景共5种）下对比了PPO、FCFS、SJF、Greedy等策略，以验证PPO是否在所有场景下都最优。

4.5.1 各场景最优策略

场景	最优策略	PPO排名	PPO vs最优差距	说明
均衡负载 (balanced)	PPO □	1	—	PPO大幅领先FCFS +88.3%

场景	最优策略	PPO排名	PPO vs最优差距	说明
高负载 (high_load)	Greedy □	2	-4.9%	队列严重积压时Greedy即时抢占略优
潮汐波动 (tidal_mix)	Greedy □	3	-19.2%	模式快速切换时Greedy响应快
突发到达 (burst)	FCFS □	2	—	突发洪峰时FCFS公平性最稳定
量子资源波动 (quantum_volatile)	PPO □	1	—	PPO比FCFS高91.4%，优势最大

详细实验数据见 `results/reports/multiscenario_benchmark.md`。


4.5.2 跨场景综合排名

策略	平均排名	稳定性评级	特点
PPO	1.8	□□□□□	唯一在所有场景进入前三，综合最优
FCFS	3.0	□□□□□	最稳定但效率低，突发场景保底
Greedy	3.2	□□	极端场景强但量子波动时崩溃(-95.3%)
SJF	3.4	□□□	中等表现，需要预知任务时长

核心发现：PPO平均排名1.8，是唯一在所有5种场景中都进入前三名的策略。Greedy虽然在高负载和潮汐场景第一，但在量子资源波动时暴跌至倒数第一（奖励-95.3%），呈现严重的两极分化。

4.5.3 场景-算法适配决策树

基于多场景测试结果，我们形成以下决策树指导策略选择：



生产环境建议：默认使用PPO，基于实时监控（队列长度>阈值、量子保真度<阈值）动态切换到保底策略。

4.5.4 诚实声明：PPO不是万能的

- 我们明确拒绝"PPO在所有场景最优"的夸大主张：
- Greedy在高负载场景领先PPO 4.9%
 - FCFS在突发洪峰场景稳定性最优
 - PPO的核心价值是跨场景的适应性和稳定性，而非单一场景的极值表现

4.6 量子赋能AI探索（阴性结果）

我们探索了"量子赋能AI"方向：使用量子退火（QA）通过QUBO映射来加速DQN的经验回放选择。结果：

- 策略质量提升：+6.4%
- 训练开销增加：+74.5%
- 统计显著性：p=0.190（未达到 $\alpha=0.05$ 显著水平）

诚实声明：量子赋能AI方向目前为探索性结果，性能提升未达统计显著，不作为核心claim。这一方向值得在未来工作中继续深入研究。

5. 真机验证

5.1 天衍云平台接入

系统已完成与中国电信天衍量子计算云平台的全链路SDK对接：

- 支持电路构造（H门、CNOT门、X/Y/Z门、T门、Toffoli门等）
- 支持任务提交、状态轮询、结果获取
- 三态熔断器保护：连续失败3次自动降级到仿真模式
- 已验证电路类型：1-3比特量子电路（H门、Bell态、QFT等）

5.2 验证结果

指标	数值
SDK调用总次数	284次
成功率	100%
覆盖操作	认证、电路提交、状态查询、结果获取
验证性质	SDK可用性验证 / 全链路打通
真机PPO均值	1665.22±324.51
真机FCFS均值	353.22±53.33

5.3 诚实声明

关于真机验证，我们做以下诚实说明：

1. 验证范围：284次调用为SDK全链路可用性验证（电路提交→执行→结果解析），非严格控制变量的性能基准测试
2. 样本量限制：真机性能对比使用5 seeds，样本量有限，量子计算机的校准状态和排队时间存在波动
3. 核心价值：真机验证的核心贡献是证明系统架构可与真实量子云平台对接，而非性能数字本身
4. 性能数据：仿真环境中N=250的严格统计结果是性能claim的主要依据

6. 落地价值与局限性

6.1 落地价值

1. 提升资源利用率：通过智能调度，预计可将量子云平台的量子比特利用率提升约30%，对应机时成本节省

- 2. 降低用户等待：在均衡负载模式下，PPO的高吞吐量意味着单位时间完成更多任务
- 3. 多模式适配：三模式调度（量子/经典/混合）适应异构计算环境
- 4. 系统可靠性：三级降级+熔断器保证生产环境稳定性
- 5. 开源透明：完整代码、模型、实验数据开源，可复现可验证

6.2 经济价值估算（基于假设）

收益项	估算金额/年	置信度
机时成本节省	¥10,950	低
科研时间价值	¥360,000	低
故障恢复节省	¥5,000	低
合计	¥375,950	低

注：经济价值估算基于假设条件（100用户规模、¥100/天机时单价等），实际效果需规模化部署验证。

6.3 局限性（诚实声明）

我们诚实报告本系统的以下局限性：

- 1. 等待时间权衡：PPO以+51%的等待时间为代价换取+88.3%的吞吐量，等待时间是权衡而非优化。不同SLO需求可通过奖励权重调整。
- 2. 量子赋能AI为探索性：量子退火加速DQN训练的方向（+6.4%，p=0.190）未达统计显著，不作为核心贡献。
- 3. 真机验证范围有限：真机验证主要证明SDK可用性，性能数字以仿真N=250结果为准，真机性能对比需扩大seeds。
- 4. 状态空间简化：当前14维状态空间是真实量子云平台复杂度的简化抽象，生产部署需扩展观测维度。
- 5. 单用户仿真：当前仿真环境为单用户模式，多租户公平调度（Jain's指数=0.9875）已初步验证但需更严格测试。
- 6. 经济估算为假设性：ROI计算基于假设参数，非真实生产数据。

6.4 未来工作

- 1. 扩大真机实验：在天衍云平台进行更多seeds的真机性能对比
- 2. 帕累托前沿分析：系统研究不同奖励权重下吞吐量-等待时间的帕累托最优曲线
- 3. 量子赋能AI深入：继续探索量子计算在RL训练加速中的应用，增大样本量
- 4. 多平台扩展：对接IBM Quantum、AWS Braket等更多量子云平台
- 5. 状态空间扩展：加入更多物理噪声模型、任务依赖关系等维度

1. Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. arXiv:1707.06347.
2. Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529-533.
3. Preskill, J. (2018). Quantum Computing in the NISQ era and beyond. *Quantum*, 2, 79.
4. Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *Annals of Mathematical Statistics*, 18(1), 50-60.
5. 中国电信量子集团. 天衍量子计算云平台API文档. 2026.
6. Raffin, A., et al. (2021). Stable-Baselines3: Reliable Reinforcement Learning Implementations. *JMLR*, 22(268), 1-8.

本技术白皮书所有数字均来自可复现的实验结果，审计脚本 `scripts/ci/audit_authoritative_metrics.py` 验证通过。