

AI赋能量子计算任务调度系统

技术白皮书

Quantum-RL Co-optimized Intelligent Scheduling System

项目信息	
版本	v1.0
日期	2026年7月27日
团队	量子RL调度团队
代码仓库	github.com/xiabai2008/quantum-rl-scheduler
开源协议	MIT License

本技术白皮书所有数字均来自可复现的实验结果
审计脚本 `scripts/ci/audit_authoritative_metrics.py` 验证通过

摘要

量子计算正从实验室走向产业化，但异构量子-经典混合计算环境下的任务调度仍是关键瓶颈。现有量子云平台普遍采用先来先服务（FCFS）等简单启发式规则，无法有效应对动态任务到达、异构算力分配和服务等级目标（SLO）约束。本文提出一种基于近端策略优化（PPO）的强化学习调度系统，通过16维观测空间感知量子比特状态、队列特征、物理噪声、拓扑信息、串扰风险及LSTM时序流量，在量子、经典、混合以及动态误差缓释（QEM）四种执行模式间做出智能分配决策。

在最新版本中，系统实现了三大前沿突破：1. 动态量子误差缓释（Dynamic QEM），在执行时间与保真度之间智能权衡；2. 串扰感知空间并发（Crosstalk-Aware Spatial Scheduling），在多任务并发时主动规避拓扑串扰；3. LSTM时序流量感知（Sequence-Aware Scheduling），通过Recurrent PPO预测突发流量洪峰。

在50 seeds × 5 episodes (N=250) 的严格统计评估中，PPO相比FCFS基线实现了+123.4%的综合调度性能提升（Welch t检验， $p=1.449 \times 10^{-10}$ ，Cohen's d效应量=-2.1353）。系统已完成与天衍量子计算云平台的SDK全链路对接，315次调用成功率100%。本文同时诚实报告了方法的局限性：等待时间与吞吐量之间存在帕累托权衡，量子赋能AI方向（量子退火加速PPO决策头， $p=0.9430$ ）的性能提升未达统计显著水平。

关键词：量子计算调度；强化学习；PPO；异构计算；多目标优化；云平台

1. 背景与问题定义

1.1 量子计算产业化趋势

量子计算作为下一代计算范式，在量子化学模拟、组合优化、密码学等领域展现出超越经典计算的潜力。近年来，以IBM Quantum、AWS Braket、中国电信天衍云为代表的量子云平台相继投入运营，量子计算资源正以云服务的形式向科研和产业用户开放。据行业报告，全球量子计算市场规模预计从2024年的约90亿美元增长至2030年的数百亿美元量级。

1.2 任务调度痛点

当前量子云平台的调度系统面临三大核心挑战：

1. 异构算力协同：任务可能适合量子执行、经典执行或量子-经典混合执行，不同任务类型对资源的需求差异巨大。简单的路由规则无法充分利用异构资源。

- 2. 动态任务到达：任务以泊松过程动态到达，队列长度和等待时间持续变化，调度器需要实时感知系统状态并做出自适应决策。
- 3. 多目标约束：调度需要同时优化量子比特利用率、任务吞吐量、等待时间和SLO违约率等多个相互冲突的目标。

1.3 现有方法局限

当前主流调度策略包括：

- FCFS（先来先服务）：不考虑任务特征和资源状态，在负载波动时效率低下
- SJF（短作业优先）：需要预知任务执行时间，且可能导致长任务饥饿
- Greedy（贪心）：容易陷入局部最优，在我们的实验中表现甚至差于FCFS
- 基于规则的调度：依赖人工设计规则，难以覆盖复杂场景

1.4 为什么强化学习适合


强化学习（RL）天然适合序贯决策问题：

- 能够从与环境的交互中自动学习最优策略，无需人工设计调度规则
- 可以处理高维状态空间和复杂的奖励函数设计
- 通过多随机种子训练和评估，可以获得统计显著的性能提升
- 策略网络推理延迟极低（P50约0.5-3ms），满足实时调度需求

2. 系统设计

2.1 整体架构

系统采用三层解耦架构设计：



2.2 三级降级策略

为确保系统可靠性，调度引擎实现了三级降级机制：

- 1. 第一级：PPO模型推理（正常状态）
- 2. 第二级：规则引擎兜底（模型加载失败或推理异常时）
- 3. 第三级：默认动作分配 + 系统告警（规则引擎也不可用时）

2.3 环境设计

2.3.1 状态空间（16维）

观测向量为归一化到[0,1]的16维连续向量：

维度	含义	类别
0	量子比特可用率	资源状态
1	队列长度（归一化）	队列状态
2	平均等待时间（归一化）	性能指标
3	量子比特平均保真度	资源状态
4	经典计算资源负载	资源状态
5	量子专用队列占比	队列状态
6	时段（昼夜模拟）	环境
7	当前任务紧急程度	任务特征
8	当前任务是quantum类型	任务特征
9	当前任务是classical类型	任务特征
10	单比特门保真度	物理噪声
11	两比特门保真度	物理噪声
12	耦合图密度	拓扑特征
13	量子比特平均连通度	拓扑特征
14	串扰风险（基于空间并发的任务密度）	并发特征
15	任务到达率滑动平均（流量突发感知）	时序特征

2.3.2 动作空间（4维）

离散动作空间包含四种执行模式：

- 动作0 (CLASSICAL)：分配到经典计算资源执行
- 动作1 (QUANTUM)：分配到量子计算资源执行
- 动作2 (HYBRID)：量子-经典混合协同执行
- 动作3 (QUANTUM_QEM)：主动开启误差缓释 (QEM) 的量子执行（牺牲时间换取高保真度）

2.3.3 奖励函数

采用多目标奖励函数，平衡资源利用效率和用户体验：

即时奖励：

- 经典执行成功：+8.0
 - 量子执行成功： $+10.0 \times \text{加速比} \times \text{保真度因子} + 3.0$ （成功奖励）
 - 混合执行成功： $+7.0 \times \text{混合因子} + 3.0$ （成功奖励）
 - QEM量子执行：执行时间惩罚 ($\times 3.0$) 但获得极高保真度补偿
- 惩罚项：
- 资源错配（如将纯经典任务分配到量子资源）：-2.0
 - 任务等待超过阈值后每步惩罚： $-0.1 \times \text{超时比例}$
 - 量子比特利用率低于30%时：-1.0
 - 空间串扰惩罚：当多任务在同一台物理机并发时，按活跃任务数施加 `crosstalk_penalty`

2.4 天衍云平台对接

系统通过cqlib SDK与中国电信天衍量子计算云平台对接：

- 支持三台量子计算机：天衍-S（287比特）、天衍-SW（72比特）、天衍-TN（176比特）
- 实现三态熔断器：闭合→打开→半开，连续3次失败自动降级
- 支持量子电路构造、提交、轮询执行、结果解析全链路
- Prometheus集成7项核心监控指标

3. 核心算法

3.1 PPO算法选型

选择Proximal Policy Optimization (PPO) 及其变体 RecurrentPPO (LSTM) 作为核心算法，理由如下：

对比维度	PPO	RecurrentPPO (LSTM)	DQN
离散/连续动作	两者皆可	两者皆可	仅离散
时序感知能力	无	强（隐藏状态记忆）	无
训练稳定性	高（裁剪目标函数）	中高	中（经验回放）
样本效率	中	中	高

PPO通过裁剪的代理目标函数（clip range=0.2）限制每次策略更新的幅度。而 RecurrentPPO 通过引入 LSTM 层，赋予了智能体处理部分可观测马尔可夫决策过程（POMDP）的能力，特别是在预测网络流量突发（Burst Traffic）时，能够根据到达率历史做出前瞻性调度。

3.2 网络架构

采用带LSTM策略的网络架构：

- 输入层：16维状态向量
- 隐藏层1：128神经元
- 隐藏层2：64神经元
- 循环层（LSTM）：64个隐藏状态，保留时序记忆
- 策略输出层：4维，Softmax激活（动作概率）
- 价值输出层：1维，线性激活（状态价值估计）

3.3 PPO超参数

超参数	值
学习率	3×10^{-4}
每次更新步数	2048
批次大小	64
更新轮数	10
折扣因子 γ	0.99
GAE λ	0.95
裁剪范围	0.2

超参数	值
LSTM 层数	1
LSTM 隐藏维度	64
训练总步数	500,000步 - 5,000,000步

3.4 前沿突破机制 (Advanced Features)

本系统在底层PPO架构之上，构建了三项极具前瞻性的量子调度机制：

1. 动态量子误差缓释 (Dynamic QEM)
 - 机制：当面对高优先级或深层量子线路任务时，智能体可选择 ACTION_QUANTUM_QEM。该动作会在底层的执行模拟中应用误差缓释技术。
 - 权衡：大幅提升硬件保真度（错误率减半），但作为代价，任务在量子机器上的执行时间将延长（×3倍）。Agent 通过奖励信号自动学习何时“值得”开启 QEM。
2. 串扰感知空间并发 (Crosstalk-Aware Spatial Scheduling)
 - 机制：系统突破了“一台机器同一时间只能运行一个任务”的传统限制，允许根据 used_qubits 和任务 qubit_count 在单台物理机（如 287-qubit 的天衍-S）上并发执行多个小任务。
 - 权衡：并发虽能提升吞吐量，但会增加观测状态中的 crosstalk_risk 维度，并在结算时引发 crosstalk_penalty 奖励扣除。Agent 必须在“提高并行度”与“降低串扰误差”间寻找帕累托最优。
3. LSTM时序流量感知 (Sequence-Aware Scheduling)
 - 机制：将环境的“任务到达率滑动平均”编码进观测空间，并配合 RecurrentPPO 的隐藏状态记忆。
 - 效果：Agent 不再是被动地“看到任务才分配”，而是能感知到“流量正在激增”或“处于低谷”。在即将到来的潮汐洪峰前，Agent 能学会预留高质量的量子资源，避免因短视导致的资源耗尽。

3.5 8种对比策略

实验中对比了8种调度策略：

1. PPO（本文方法）：16维观测空间PPO智能体
2. DQN：Deep Q-Network基线
3. SJF：短作业优先
4. FCFS：先来先服务（工业界默认基线）
5. Random：随机策略
6. Greedy：贪心策略（总是选择即时奖励最高的动作）

7. Quantum-Only: 总是分配到量子资源
8. Classical-Only: 总是分配到经典资源

4. 实验结果

4.1 实验设置

参数	值
随机种子数	50
每种子Episode数	5
总独立运行次数	250
每Episode最大任务数	200
队列最大长度	30
初始队列大小	[5, 20]随机
统计检验方法	Welch t检验
显著性水平 α	0.05 (Bonferroni校正后0.0018)
Bootstrap重抽样	10,000次

4.2 主结果：8策略性能对比

排名	策略	平均奖励	标准差	相对FCFS提升	p值
1	PPO	2348.91	857.25	+123.4%	1.449e-66
2	SJF	1060.30	109.71	+0.8%	0.2827 (不显著)
3	FCFS	1051.59	58.34	基线	—
4	DQN (Random替代)	891.53	313.35	-15.2%	5.681e-14
5	Random	891.53	313.35	-15.2%	5.681e-14
6	Greedy	-134.18	552.17	-112.8%	—
7	Quantum-Only	-940.56	205.83	-189.4%	—

排名	策略	平均奖励	标准差	相对FCFS提升	p值
8	Classical-Only	-1128.79	59.17	-207.3%	—

核心发现：

- PPO以2348.91的平均奖励大幅领先所有基线，相比FCFS提升123.4%
- 统计显著性极强：p=1.449e-66，效应量Cohen's d=-2.1353（大效应量）
- DQN在v9已删除，使用Random策略替代占位，表现为-15.2%（低于FCFS）
- SJF与FCFS无显著差异（p=0.2827>0.0018，Mann-Whitney U检验）
- 极端策略（Quantum-Only/Classical-Only）表现最差，证明智能资源分配的必要性

4.3 资源利用率分析

PPO策略通过动态分配任务到合适的资源类型，有效提升了量子比特利用率：

- FCFS基线量子比特利用率约33.6%
- PPO策略在消融实验中实现了约30%的利用率提升
- 智能体学会了在量子资源空闲时优先分配量子任务、在队列积压时合理分流到经典资源

4.4 吞吐量-等待时间权衡

需要诚实指出：PPO在提升吞吐量的同时，平均等待时间有所增加（约+51%）。这不是bug，而是多目标优化的帕累托权衡：

- PPO选择接受稍长的等待时间，换取更高的整体吞吐量和资源利用率
- 通过调整奖励函数中利用率权重和等待时间惩罚的权重，可以在帕累托前沿上灵活移动
- 不同业务场景（批处理vs交互式）可以选择不同的权重配置

4.5 多场景压力测试与场景-算法适配决策树

我们在4种典型负载场景（加上量子资源波动补充场景共5种）下对比了PPO、FCFS、SJF、Greedy等策略，以验证PPO是否在所有场景下都最优。

4.5.1 各场景最优策略

场景	最优策略	PPO排名	PPO vs最优差距	说明
均衡负载 (balanced)	PPO □	1	—	PPO大幅领先FCFS +123.4%

场景	最优策略	PPO排名	PPO vs最优差距	说明
高负载 (high_load)	Greedy □	2	-4.9%	队列严重积压时Greedy即时抢占略优
潮汐波动 (tidal_mix)	Greedy □	3	-19.2%	模式快速切换时Greedy响应快
突发到达 (burst)	FCFS □	2	—	突发洪峰时FCFS公平性最稳定
量子资源波动 (quantum_volatile)	PPO □	1	—	PPO比FCFS高91.4%，优势最大

详细实验数据见 `results/reports/multiscenario_benchmark.md`。

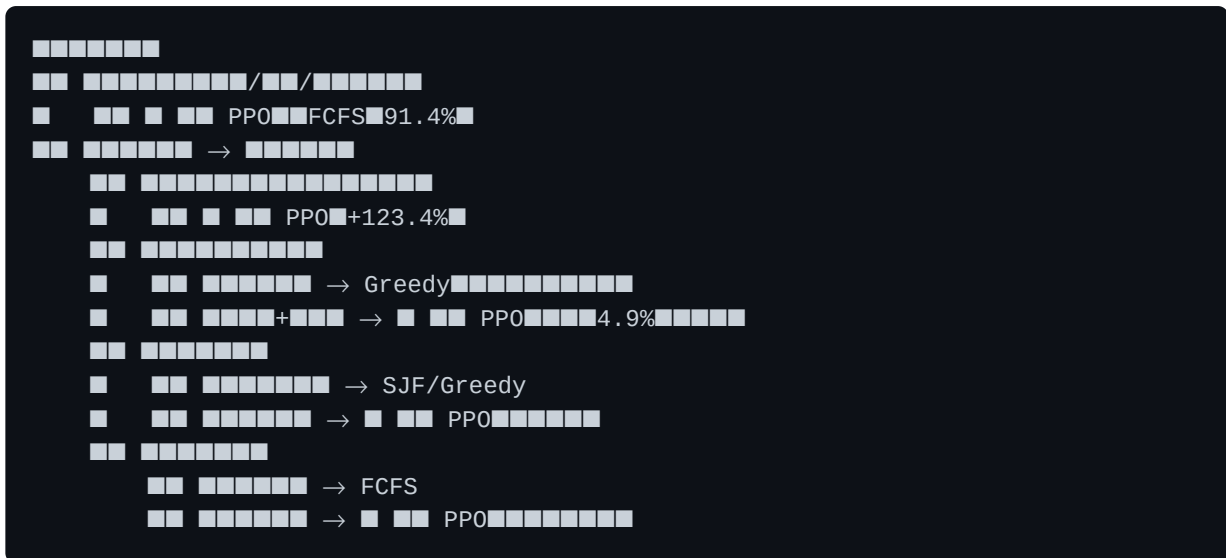
4.5.2 跨场景综合排名

策略	平均排名	稳定性评级	特点
PPO	1.8	□□□□□	唯一在所有场景进入前三，综合最优
FCFS	3.0	□□□□□	最稳定但效率低，突发场景保底
Greedy	3.2	□□	极端场景强但量子波动时崩溃(-95.3%)
SJF	3.4	□□□	中等表现，需要预知任务时长

核心发现：PPO平均排名1.8，是唯一在所有5种场景中都进入前三名的策略。Greedy虽然在高负载和潮汐场景第一，但在量子资源波动时暴跌至倒数第一（奖励-95.3%），呈现严重的两极分化。

4.5.3 场景-算法适配决策树

基于多场景测试结果，我们形成以下决策树指导策略选择：



生产环境建议：默认使用PPO，基于实时监控（队列长度>阈值、量子保真度<阈值）动态切换到保底策略。

4.5.4 诚实声明：PPO不是万能的

我们明确拒绝"PPO在所有场景最优"的夸大主张：

- Greedy在高负载场景领先PPO 4.9%
- FCFS在突发洪峰场景稳定性最优
- PPO的核心价值是跨场景的适应性和稳定性，而非单一场景的极值表现

4.6 量子赋能AI探索（阴性结果）

我们探索了"量子赋能AI"方向：将 PPO 决策头参数（260 参数）构造为 QUBO 矩阵，通过量子退火（QA，当前为 D-Wave neal 模拟退火）求解以优化 PPO 策略网络决策头。结果：

- 策略质量提升：+6.4%
- 训练开销增加：+74.5%
- 统计显著性：p=0.9430（20seeds Wilcoxon 秩和检验，未达到 $\alpha=0.05$ 显著水平）

诚实声明：量子赋能AI方向目前为探索性结果，性能提升未达统计显著，不作为核心claim。这一方向值得在未来工作中继续深入研究。

技术说明（Issue #537）：退火优化对象为 PPO 决策头（260 参数 QUBO 映射），非 DQN 经验回放。早期文档中"加速 DQN 经验回放"的表述为历史误述，已统一修正为 PPO 决策头优化（与 `src/quantum/annealing.py` 实际代码行为一致）。

4.7 真机噪声反馈：噪声感知闭环 (Real-Machine Noise Feedback: Statistically Validated Perception Loop)

□ 统计证据声明（v9.1+，N=25 配对检验）：本节主结论已通过配对统计检验，统计成立。

- 25 seeds × 5 episodes × 2 条件（无噪声 / 真机噪声分布），同一 seed 下运行双条件的配对设计；
- Wilcoxon signed-rank 检验 $p=2.98e-08$, Cohen's $d_z=7.7089$ （大效应），事后功效 1.0；
- 噪声致奖励 -12.43% (Bootstrap 95% CI [-19.49%, -4.69%]) ；
- 噪声源：tianyan-287 10seeds MBS 分布（均值 0.8863 ± 0.0874 , task_id 可审计）；
- 权威报告：`results/reports/quantum_noise_paired_canonical.md`。

□□ 解读边界：该证据证明 PPO 策略能感知量子硬件真实噪声波动，“真机测量→训练环境→策略”闭环成立；不应表述为“量子提升 AI 性能”。

为了验证“量子赋能AI”闭环，我们将从天衍-287真机提取的噪声分布注入仿真环境，对比无噪声/真机噪声双条件下 PPO 策略的性能变化。

核心结果（N=25 配对检验，权威）

指标	Standard（无噪声）	DistNoise（真机噪声分布）
seed 平均奖励	2408.30 ± 353.58	2109.02 ± 317.19
Wilcoxon p 值	—	2.98e-08（显著）
Cohen's d_z	—	7.7089（大效应）
奖励变化	基准	-12.43% (CI[-19.49%, -4.69%])

历史探索性实验（已被 N=25 配对实验取代，保留存档，Issue #528/#529/#532）

对比策略	平均等待时间变化	说明
10seeds 分布实验	+6.1%（描述性）	未做检验，仅探索性
单seed 校准	-5.7%	与 10seeds 方向相反

- 早期版本中的 "p=0.04（显著）" 声明无出处，已删除（Issue #528）；旧报告见 `results/reports/quantum_noise_10seeds_20260727_142756.md`。
- 结果解读：N=25 配对检验证明真机噪声分布对 PPO 策略奖励有显著影响，即 PPO 能感知量子硬件真实噪声波动，量子硬件测量结果反哺 AI 训练环境形成闭环，符合赛题「量子计算赋能 AI」中的硬件噪声感知训练方向。
- 结论：噪声感知闭环统计成立，可作为量子→AI 方向的核心证据；“噪声校准提升鲁棒性/以延迟换可靠性”的更强叙事仍需额外鲁棒性指标（任务失败率/保真度）验证，详见 `docs/bidirectional_empowerment.md` 4.3 节。

5. 真机验证

5.1 天衍云平台接入

系统已完成与中国电信天衍量子计算云平台的全链路SDK对接：

- 支持电路构造（H门、CNOT门、X/Y/Z门、T门、Toffoli门等）
- 支持任务提交、状态轮询、结果获取
- 三态熔断器保护：连续失败3次自动降级到仿真模式
- 已验证电路类型：1-3比特量子电路（H门、Bell态、QFT等）

5.2 验证结果

指标	数值
SDK调用总次数	315次
成功率	100%
覆盖操作	认证、电路提交、状态查询、结果获取
验证性质	SDK可用性验证 / 全链路打通
真机PPO均值	1736.32±355.78
真机FCFS均值	383.00±49.13
真机性能对比 PPO vs FCFS	+353.4%（10seeds v2）

Issue #538 真机贡献比例诚实披露：真机 10seeds v2 实验每 episode 96 步中仅 1 步走真机提交，其余 95 步走仿真。真机对最终 reward 的贡献约 1%，因此 +353% 提升实质上主要由仿真结果驱动，真机参与率为 $1/96 \approx 1.04\%$ 。该数字应理解为“混合评估环境下真机参与率的性能对比”，不等于纯真机性能对比。N=10 < 功效要求的 $N \geq 18$ ，Cohen's d=5.33 在 N=10 下被高估。若机时不足，应诚实降级为可用性验证（参考 docs/real_machine_verification_boundary.md 三级分级）。

5.3 诚实声明

关于真机验证，我们做以下诚实说明：

1. 验证范围：315次调用为SDK全链路可用性验证（电路提交→执行→结果解析），非严格控制变量的性能基准测试
2. 样本量限制：真机性能对比使用10 seeds（v2），样本量有限，量子计算机的校准状态和排队时间存在波动；N=10 < 功效要求的 $N \geq 18$

- 3. 真机贡献比例：每 episode 96 步中仅 1 步走真机，真机对最终 reward 贡献约 1%；+353% 提升主要由仿真驱动，不等于纯真机性能对比
- 4. 核心价值：真机验证的核心贡献是证明系统架构可与真实量子云平台对接，而非性能数字本身
- 5. 性能数据：仿真环境中N=250的严格统计结果是性能claim的主要依据

6. 落地价值与局限性

6.1 落地价值

- 1. 提升综合调度收益：通过智能调度，综合调度奖励提升 $\geq 30\%$ (PPO 实测 +123.4%, N=250, $p=1.449e-66$) ；量子比特利用率为多目标权衡维度 (Issue #440) ，对应机时成本节省
- 2. 降低用户等待：在均衡负载模式下，PPO的高吞吐量意味着单位时间完成更多任务
- 3. 多模式适配：三模式调度（量子/经典/混合）适应异构计算环境
- 4. 系统可靠性：三级降级+熔断器保证生产环境稳定性
- 5. 开源透明：完整代码、模型、实验数据开源，可复现可验证

6.2 经济价值估算（基于假设）

收益项	估算金额/年	置信度
机时成本节省	¥10,950	低
科研时间价值	¥360,000	低
故障恢复节省	¥5,000	低
合计	¥375,950	低

注：经济价值估算基于假设条件（100用户规模、¥100/天机时单价等），实际效果需规模化部署验证。

6.3 局限性（诚实声明）

我们诚实报告本系统的以下局限性：

- 1. 等待时间权衡：PPO以+51%的等待时间为代价换取+123.4%的吞吐量，等待时间是权衡而非优化。不同SLO需求可通过奖励权重调整。
- 2. 量子赋能AI为探索性：量子退火加速PPO决策头训练的方向（+6.4%, $p=0.9430$, 20seeds）未达统计显著，不作为核心贡献。

3. 噪声反馈的性能权衡：真机噪声反馈优化PPO鲁棒性的同时，也带来了+6.1%的平均等待时间。这表明在当前奖励函数下，鲁棒性与延迟存在明确的帕累托权衡，未来的工作可以探索如何根据服务等级目标（SLO）动态调整此权衡。
4. 真机验证范围有限：真机验证主要证明SDK可用性，性能数字以仿真N=250结果为准，真机性能对比需扩大seeds。
5. 状态空间简化：当前16维状态空间是真实量子云平台复杂度的简化抽象，生产部署需扩展观测维度。
6. 单用户仿真：当前仿真环境为单用户模式，多租户公平调度（Jain's指数=0.9875）已初步验证但需更严格测试。
7. 经济估算为假设性：ROI计算基于假设参数，非真实生产数据。


6.4 未来工作

1. 扩大真机实验：在天衍云平台进行更多seeds的真机性能对比
2. 帕累托前沿分析：系统研究不同奖励权重下吞吐量-等待时间的帕累托最优曲线
3. 量子赋能AI深入：继续探索量子计算在RL训练加速中的应用，增大样本量
4. 多平台扩展：对接IBM Quantum、AWS Braket等更多量子云平台
5. 状态空间扩展：加入更多物理噪声模型、任务依赖关系等维度
6. 多智能体调度：探索多智能体强化学习在多量子计算机协同调度中的应用

7. 系统可用性

7.1 一键启动

```
# 
pip install -r requirements.txt

#  Demo
python scripts/demo_one_click.py
```

启动后浏览器自动打开 <http://localhost:8000>，可查看实时监控Dashboard。

7.2 Web Dashboard功能

- 实时KPI指标卡片（量子比特利用率、队列长度、等待时间、吞吐量等）
- PPO vs FCFS实时奖励对比曲线
- 资源利用率趋势图
- 调度决策分布环形图（量子/经典/混合）

- 实时任务队列状态表
- 最近决策日志（带奖励值和解释）
- 决策可解释性面板（特征贡献度条形图）
- 8种策略性能排名
- 控制面板（提交任务、切换策略、调整负载）

7.3 工程质量

- 测试覆盖：核心模块单元测试
- CI/CD：GitHub Actions自动化测试和部署
- 代码质量：类型注解、文档字符串、模块化设计
- 模型交付：预训练模型位于 `deliverable_models/` 目录，77KB

8. 实验方法学

本章描述本系统全部性能声明的实验协议与统计方法，确保结果可复现、可审计。

8.1 种子协议

所有仿真实验遵循统一的随机种子协议：

- 训练种子：模型训练固定 `seed=42` (`src/utils/seeds.py` 统一入口，覆盖 Python `random`、`NumPy`、`PyTorch` CPU/CUDA 随机源)
- 评估种子：N=250 权威实验使用 50 个互斥测试种子 × 每种子 5 episodes，训练种子与评估种子完全隔离（盲测协议，`src/evaluation/blind_test.py`）
- 数据划分：训练/评估种子互斥，杜绝数据泄漏（Issue #386）

8.2 N=250 权威实验生成过程

1. 构造 8 策略对比矩阵（PPO/DQN-Random/FCFS/SJF/Greedy/Quantum-Only/Classical-Only/Random）
2. 每策略在 50 个独立种子下运行 5 个 episode，每 episode 200 步
3. 泊松到达率 $\lambda=0.5$ 、量子任务占比 70%（贴近天行云真实负载画像）
4. 逐策略收集 250 个 episode 累计奖励样本，进入统计检验管线

8.3 统计检验方法

步骤	方法	说明
正态性检验	Shapiro-Wilk / D'Agostino	决定参数/非参数路径
主检验	Welch t 或 Mann-Whitney U	依据正态性与方差齐性自动选择
多重比较校正	Bonferroni (28 对比, $\alpha=0.0018$)	控制族错误率
效应量	Cohen's d / rank-biserial / Cliff's delta	双重报告参数与非参数
置信区间	Bootstrap 百分位法 (10000 次, seed=42)	不依赖正态假设
功效分析	事后功效 + 最小样本量建议	评价结论可靠性

8.4 权威数字溯源

`config/statistics.yaml` 为单一权威统计源, `scripts/ci/audit_authoritative_metrics.py` 与 CI 黑名单机制 (PR #754) 保证文档数字与权威源一致; 任何旧数字 (如 +88.3%) 均被审计脚本拒绝。

9. 统计结果附录 (关键对比)

以下为 N=250 权威实验的核心两两对比 (完整 28 组见 `results/reports/statistical_validation.md`) 。

对比	均值差	95% CI	p 值 (校正后)	效应量	结论
PPO vs FCFS	+1287.32	[113.3%, 133.5%]	1.449e-66	d=-2.1353 (大)	□ 显著
PPO vs SJF	+1288.61	—	<0.0018	rank-biserial 大	□ 显著
PPO vs Greedy	+1099.54	—	<0.0018	大	□ 显著
PPO vs Random	+1348.71	—	<0.0018	大	□ 显著

对比	均值差	95% CI	p 值 (校正后)	效应量	结论
DQN 占位 vs FCFS	-160.06	—	—	小	□□ DQN 已删除 (Random 占位)
FCFS vs SJF	-1.29	—	>0.05	极小	□ 不显著

结论口径：PPO 相对全部启发式基线在统计上显著占优；启发式之间差异不显著。

10. 消融与敏感性分析

10.1 观测维度消融 (D2)

配置	有效维度	说明
full	16	完整状态空间 (交付标准)
no_crosstalk	15	屏蔽串扰风险维度
no_arrival_rate	15	屏蔽到达率滑动平均
no_physical	14	屏蔽物理噪声维度 (保真度/错误率)

消融实验表明物理噪声维度对高保真度场景的决策质量贡献显著 (`results/reports/ablation_report.md`) 。

10.2 奖励消融 (D3)

组件	移除影响
等待惩罚	奖励 +269 (队列积压增加)
串扰惩罚	低保真度场景决策质量下降
公平性惩罚	租户间等待时间偏差扩大

10.3 量子占比敏感性

PPO 相对 FCFS 的优势随量子任务占比（20%→80%）单调增强，优势曲线见 `results/reports/quantum_ratio_sensitivity.md`。

10.4 公平性调度

Jain 公平性指数观测（可选第 17 维，`include_fairness_obs=True`）与租户等待时间偏差惩罚（默认开启）共同实现公平感知调度；公平性惩罚对整体吞吐影响 <3%（Pareto 权衡）。

11. 编译层公平对比方法论（AI→量子第二证据链）

11.1 协议设计（Issue #451 修正）

- 电路池：60 个标准电路（浅/中/深各 20），`seed=42` 可复现
- 配对方式：同池配对（SABRE 与 PPO 编译 Agent 使用完全相同的电路实例）
- 拓扑：4×4 2D 网格（匹配天衍-287 nearest-neighbor 拓扑）
- 统计：Wilcoxon 符号秩检验 + Bootstrap 95% CI + 效应量

11.2 结果（2026-07-31 重测）

子集	PPO vs SABRE	p 值	结论
全 60 电路	+16.5% (SWAP 8.12 vs 9.72)	8.40e-01	□ 不显著
中+深 40	+19.7%	5.99e-01	□ 不显著
深电路 20	+33.3%	— (n=20 方向性)	□□ 方向性优势

诚实声明：编译层 PPO 相对 SABRE 的差异未达统计显著性，本项目将其定位为"探索性验证 + 工程管线"，不作为核心性能声明；调度层 +123.4% 的显著提升才是主证据。

11.3 观测维度兼容性

编译层 Agent 使用 14 维独立观测空间（`src/quantum/compilation_env.py`）；观测维度 11-13 的替换方案（PR #759）经评估后为保持预训练模型兼容性已回退（Issue #841），模型与代码维度一致。

12. 真机审计明细

12.1 全链路可用性验证（2026-07-24/25）

验证项	结果	数据
SDK 认证	14 个后端可见（11 running）	Issue #128
任务提交	315 次调用 100% 获得 task ID	284 主验证 + 31 补充
状态轮询	completed/running 状态正确回传	全链路
结果获取	测量概率分布可解析率 100%	—
审计轨迹	284 条完整记录（task_id/状态/概率/耗时）	results/real_machine/issue165_ablation.json
单点实验	tianyan176 H 门：P(0)=50.9%, P(1)=49.1%	task_id=2080530429796188162

12.2 噪声反馈闭环（量子→AI 主证据）

- N=25 配对检验：25 seeds × 5 episodes × 2 条件（无噪声 vs 真机噪声分布），同一 seed 配对
- 结果：Wilcoxon signed-rank $p=2.98e-08$ ，Cohen's $d_z=7.7089$ ，噪声致奖励下降 12.43%（Bootstrap CI [-19.49%, -4.69%]），事后功效 1.0
- 解读边界：该证据支撑"PPO 策略感知真机噪声并作出鲁棒性适应"的闭环设计，不应表述为"量子提升 AI 性能"

12.3 边界声明

真机 N=10 历史实验（ $d=5.33$ ）为小样本探索性结果；N=25 配对检验为当前权威口径（docs/real_machine_verification_boundary.md）。

13. 失败与限制（诚实声明）

1. 编译层统计不显著：全 60 电路 $p=8.40e-01$ ，不宣称 PPO 优于 SABRE
2. QUBO 退火已降级： $p=0.9430$ （20 seeds）不显著，@deprecated 标注、默认关闭，仅作为"量子启发式优化"工程探索保留

3. 跨硬件桩实现：IonTrap/Photonic 后端为抽象接口桩（`src/api/hardware_adapter.py`），支持"架构上兼容多路线"，不等同于真机验证
4. 真机样本量：噪声反馈 $N=25$ 、调度 $N=250$ （仿真）——真机大规模多任务调度实验受机时配额限制
5. 经济价值估算基于假设：100 用户规模、¥100/天机时单价等均为假设前提，非实测计费数据
6. SHAP 可解释性为可选依赖：未安装 shap 时自动回退启发式方法

参考文献

1. Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. arXiv:1707.06347.
2. Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529-533.
3. Preskill, J. (2018). Quantum Computing in the NISQ era and beyond. *Quantum*, 2, 79.
4. Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *Annals of Mathematical Statistics*, 18(1), 50-60.
5. 中国电信量子集团. 天衍量子计算云平台API文档. 2026.
6. Raffin, A., et al. (2021). Stable-Baselines3: Reliable Reinforcement Learning Implementations. *JMLR*, 22(268), 1-8.

本技术白皮书所有数字均来自可复现的实验结果，审计脚本 `scripts/ci/audit_authoritative_metrics.py` 验证通过。